

山东大学计算机科学与技术学院

机器学习与模式识别 课程实验报告

学号： 201700301042	姓名： 陈佳睿	班级： 17 人工智能
实验题目：线性判别分析（LDA）		
实验目的：利用给定的一个三分类数据，实现线性判别的二分类方法和多分类方法		
硬件环境： Macbook pro 8GB 内存		
软件环境： Macos majove , octave		
<p>实验步骤与内容：</p> <p>LDA 在模式识别领域中有广泛的应用，它是一种监督学习下的降维技术</p> <p>其核心思想为”投影后类内方差最小，类间方差最大”</p> <p>我们要将数据在低维度上进行投影，投影后希望每个类别数据的投影点尽可能的接近，不同类别的数据的类别中心之间的距离尽可能的大</p> <p>一. 数学基础知识</p> <p>LDA原理与流程</p> <p>给定数据集 <math>\{(\mathbf{x}_i, y_i)\}_{i=1}^m</math></p> <p>第 <math>i</math> 类示例的集合 <math>X_i</math></p> <p>第 <math>i</math> 类示例的均值向量 <math>\mu_i</math></p> <p>第 <math>i</math> 类示例的协方差矩阵 <math>\Sigma_i</math></p> <p>两类样本的中心在直线上的投影：<math>w^T \mu_0</math> 和 <math>w^T \mu_1</math></p> <p>两类样本的协方差：<math>w^T \Sigma_0 w</math> 和 <math>w^T \Sigma_1 w</math></p>		

同类样例的投影点尽可能接近  $\rightarrow w^T \Sigma_0 w + w^T \Sigma_1 w$  尽可能小  
 异类样例的投影点尽可能远离  $\rightarrow \|w^T \mu_0 - w^T \mu_1\|_2^2$  尽可能大

于是, 最大化

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} = \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

类内散度矩阵 (within-class scatter matrix)

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T \end{aligned}$$

类间散度矩阵 (between-class scatter matrix)

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$

LDA的目标: 最大化广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{w^T S_b w}{w^T S_w w} \quad \begin{array}{l} w \text{ 成倍缩放不影响 } J \text{ 值} \\ \text{仅考虑方向} \end{array}$$

令  $w^T S_w w = 1$ , 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_w & -w^T S_b w \\ \text{s.t. } & w^T S_w w = 1 \end{aligned}$$

运用拉格朗日乘子法, 有  $S_b w = \lambda S_w w$

$S_b w$  的方向恒为  $\mu_0 - \mu_1$ , 不妨令  $S_b w = \lambda (\mu_0 - \mu_1)$

$$\text{于是 } w = S_w^{-1} (\mu_0 - \mu_1)$$

实践中通常是进行奇异值分解  $S_w = U \Sigma V^T$

$$\text{然后 } S_w^{-1} = V \Sigma^{-1} U^T$$

$\longrightarrow \beta$

假定有  $N$  个类

$$\begin{aligned} \square \text{ 全局散度矩阵} \quad \mathbf{S}_t &= \mathbf{S}_b + \mathbf{S}_w = \sum_{i=1}^m (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T \\ \square \text{ 类内散度矩阵} \quad \mathbf{S}_w &= \sum_{i=1}^N \mathbf{S}_{w_i} \quad \mathbf{S}_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T \\ \square \text{ 类间散度矩阵} \quad \mathbf{S}_b &= \mathbf{S}_t - \mathbf{S}_w = \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T \end{aligned}$$

多分类LDA有多种实现方法：采用  $\mathbf{S}_b$ ,  $\mathbf{S}_w$ ,  $\mathbf{S}_t$  中的任何两个

$$\text{例如, } \max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})} \Rightarrow \mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$$

$$\mathbf{W} \in \mathbb{R}^{d \times (N-1)}$$

$\mathbf{W}$  的闭式解是  $\mathbf{S}_w^{-1} \mathbf{S}_b$  的  $N-1$  个最大广义特征值所对应的特征向量组成的矩阵

## 二. octave 对于数据进行二分类

### 1. 数据读取

```
>> xb = load('ex3blue.dat');
```

```
>> xr = load('ex3red.dat');
```

```
>> xg = load('ex3green.dat');
```

### 2. 投影向量 $w$ 的计算

```
>> mb = mean(xb);
```

```
>> mr = mean(xr);
```

```
>> Sw = (xb-mb)'*(xb-mb)+(xr-mr)'*(xr-mr);
```

```
>> w = inv(Sw)*(mb-mr)';
```


```
>> w = abs(w)/sqrt(w'*w); //这里我将 w 进行了单位化
```

```
>> x = [0:0.01,10];
```

```
>> y = (w(2)/w(1))*x;
```


```
>> zb = xb*w*w';
```

```
>> zr = xr*w*w';
```



最终得到的二分类图像结果如上图

接下来我根据高斯公式，将我降维数据的分布曲线绘制出来



二分类的数据分布的交叉部分比较少，所以可以认为使用 lda 进行降维的效果比较好

## 二. 多分类（本实验为 3 分类）

### 1. 定义全局散度函数

$$S_t = S_b + S_w = \sum_{i=1}^m (x_i - \mu)(x_i - \mu)^T$$

其中  $\mu$  为全部数据的均值：

$$\mu = \frac{1}{N} \sum_{i=1}^C n_i \mu_i$$

在多分类问题下，类间散度矩阵定义如下：

$$S_b = S_t - S_w = \sum_{i=1}^N m_i (\mu_i - \mu)(\mu_i - \mu)^T$$

### 2. 多分类的优化即为实现以下函数：

$$\max \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_w W)}$$

### 3. 多分类实现

#### 1) 求解投影矩阵 $w$

有了以上实验进行二分类 lda 的经验，根据上述列出的计算公式我们可以很快通过 octave 计算出三个类的全局散度和三个类的类内散度值之和，并由此计算出类间的散度矩阵

```
>> St = (xb-ma)'*(xb-ma)+(xr-ma)'*(xr-ma)+(xg-ma)'*(xg-ma);
```


```
>> Sw = (xb-mb)'*(xb-mb)+(xr-mr)'*(xr-mr)+(xg-mg)'*(xg-mg);
```

```
>> Sb = St - Sw;
```

```
>> [vec , val] = eig(inv(Sw)*Sb);
```

使用 octave 提供的 eig 函数

计算出  $S_w$  的逆矩阵点乘  $S_b$  所得到的矩阵的特征向量和特征值




最终分类的结果如上图所示

依旧使用高斯函数来进行统计和分布绘制

得到下面的数据分布图

三者的交叉区域比较少，三分类的任务通过 lda 算法也完成地比较好



## 结论分析与体会：

### LDA与PCA

LDA用于降维，和PCA有很多相同，也有很多不同的地方，因此值得好好的比较一下两者的降维异同点。

#### 相同点

- 1) 两者均可以对数据进行降维。
- 2) 两者在降维时均使用了矩阵特征分解的思想。
- 3) 两者都假设数据符合高斯分布。

#### 不同点

- 1) LDA是有监督的降维方法，而PCA是无监督的降维方法
- 2) LDA降维最多降到类别数 $k-1$ 的维数，而PCA没有这个限制。
- 3) LDA除了可以用于降维，还可以用于分类。
- 4) LDA选择分类性能最好的投影方向，而PCA选择样本点投影具有最大方差的方向。这点可以从下图形象的看出，在某些数据分布下LDA比PCA降维较优。

### LDA小结

LDA算法既可以用来降维，又可以用来分类，但是目前来说，主要还是用于降维。在进行图像识别相关的数据分析时，LDA是一个有力的工具。下面总结下LDA算法的优缺点。

#### 优点

- 1) 在降维过程中可以使用类别的先验知识经验，而像PCA这样的无监督学习则无法使用类别先验知识。
- 2) LDA在样本分类信息依赖均值而不是方差的时候，比PCA之类的算法较优。

#### 缺点

- 1) LDA不适合对非高斯分布样本进行降维，PCA也有这个问题。
- 2) LDA降维最多降到类别数 $k-1$ 的维数，如果我们降维的维度大于 $k-1$ ，则不能使用LDA。当然目前有一些LDA的进化版算法可以绕过这个问题。
- 3) LDA在样本分类信息依赖方差而不是均值的时候，降维效果不好。
- 4) LDA可能过度拟合数据。

代码:

```
>> xb = load('ex3blue.dat');
>> xr = load('ex3red.dat');
>> xg = load('ex3green.dat');
>> mb = mean(xb);
>> mr = mean(xr);
>> Sw = (xb-mb)*(xb-mb)+(xr-mr)*(xr-mr);
>> w = inv(Sw)*(mb-mr);
>> w = abs(w)/sqrt(w'*w);
>> x=[0:0.01,10];
>> y = (w(2)/w(1))*x;
>> zb = xb*w*w';
>> zr = xr*w*w';
>> figure
>> plot(xb(:,1),xb(:,2),'bx');
>> hold on
>> plot(xr(:,1),xr(:,2),'rx');
>> hold on
>> plot(x,y,'-d');
>> plot(zb(:,1),zb(:,2),'bx');
>> hold on
>> plot(zr(:,1),zr(:,2),'rx');
>> xlabel('feature 1');
>> ylabel('feature 2');
>> legend('data blue','data red','LDA','line blue','line red');
>> title('bi-classification');
```



图表绘制:

```
>> yb = xb*w;
>> yr = xr*w;
>> std_blue = std(yb);
>> std_red = std(yr);
>> tb = [mean_blue-4*std_blue:0.01:mean_blue+4*std_blue];
>> tr = [mean_red-4*std_red:0.01:mean_red+4*std_red];
>> figure
>> plot(tb,exp(-(tb-mean_blue).*(tb-mean_blue)/(2*std_blue^2))/std_blue*sqrt(2*pi),
'b-')
>> hold on
>> plot(tr,exp(-(tr-mean_red).*(tr-mean_red)/(2*std_red^2))/std_red*sqrt(2*pi),'r-')
>> title("distribution of data")
>> legend('data blue','data red');
```

多分类任务:

```
>> mg = mean(xg);
>> nb = length(xb);
>> nr = length(xr);
>> ng = length(xg);
>> na = nb+nr+ng;
>> ma = (nb*mb+nr*mr+ng*mg)/na;
>> St = (xb-ma)*(xb-ma)+(xr-ma)*(xr-ma)+(xg-ma)*(xg-ma);
>> St = (xb-ma)*(xb-ma)+(xr-ma)*(xr-ma)+(xg-ma)*(xg-ma);
>> Sw = (xb-mb)*(xb-mb)+(xr-mr)*(xr-mr)+(xg-mg)*(xg-mg);
error: index (-0.165): subscripts must be either integers 1 to (2^63)-1 or logicals
>> Sw = (xb-mb)*(xb-mb)+(xr-mr)*(xr-mr)+(xg-mg)*(xg-mg);
>> Sb = St - Sw;
>> [vec , val] = eig(inv(Sw)*Sb);
>> [vec,val]
ans =
```

0.93089	-0.74596	11.22001	0.00000
0.36531	0.66600	0.00000	0.26049

```
>> lamda = max(diag(val));
>> W = vec(:,find(diag(val)==lamda));
>> x = [0:0.01,10];
>> y = (W(2)/W(1))*x;
>> zb = xb*W*W';
>> zr = xr*W*W';
>> zf = xg*W*W';
>> zg = xg*W*W';
>> figure
```

```

>> plot(xb(:,1),xb(:,2),'bx');
>> hold on
>> plot(xr(:,1),xr(:,2),'rx');
>> hold on
>> plot(xg(:,1),xg(:,2),'gx');
>> hold on
>> plot(x,y,'-d');
>> plot(zb(:,1),zb(:,2),'bx');
>> hold on
>> plot(zr(:,1),zr(:,2),'rx');
>> hold on
>> plot(zg(:,1),zg(:,2),'gx');
>> xlabel('feature 1');
>> ylabel('feature 2');
>> legend('data blue','data red','data green','LDA','line blue','line red','line green');
>> title('multi-classification');
>> yg = xg*W;
>> std_green =std(yg);
std_green = 0.64029
>> mean_green = mean(yg);
mean_green = 7.7865
>> tg = [mean_green-4*std_green:0.01:mean_green+4*std_green];
>> figure
>> plot(tb,exp(-(tb-mean_blue).*(tb-mean_blue)/(2*std_blue^2))/std_blue*sqrt(2*pi),
'b-')
>> plot(tr,exp(-(tr-mean_red).*(tr-mean_red)/(2*std_red^2))/std_red*sqrt(2*pi),'r-')
>> plot(tg,exp(-(tg-mean_green).*(tg-mean_green)/(2*std_green^2))/std_green*sqrt(2*pi),'g-')
>> hold on
>> plot(tb,exp(-(tb-mean_blue).*(tb-mean_blue)/(2*std_blue^2))/std_blue*sqrt(2*pi),
'b-')
>> hold on
>> plot(tr,exp(-(tr-mean_red).*(tr-mean_red)/(2*std_red^2))/std_red*sqrt(2*pi),'r-')
>> hold on
>> title('distribution of data');
>> legend('data blue','data red','data green');

```